

Proyecto de Especialización "Data Analyst" 2026

Una mirada a las Ofertas de Data Analyst en Barcelona usando Web Scraping y NLP

Rossemay Castellanos Perez
IT Academy
Correo-e: castellanorn@gmail.com

Resumen. *El presente estudio analiza ofertas de empleo para el perfil de Data Analyst en la ciudad de Barcelona mediante un enfoque combinado de Web Scraping y Procesamiento del Lenguaje Natural (NLP). El objetivo principal es identificar habilidades, requisitos y tendencias más relevantes en el mercado laboral actual, así como evaluar la consistencia de la información publicada en distintos portales de empleo. La recopilación de datos se realizó a través de scraping automatizado en Indeed y LinkedIn, complementado con el uso de la API de Adzuna. Posteriormente, se aplicaron procesos de limpieza, depuración y estandarización para consolidar un conjunto de ofertas homogéneo. Las descripciones textuales fueron procesadas mediante técnicas NLP para extraer skills técnicas y transversales, clasificar familias profesionales y estructurar requisitos laborales como modalidad, jornada, educación y experiencia.*

Los resultados muestran fuerte demanda de habilidades técnicas como Python, SQL, herramientas de visualización y conocimientos estadísticos. Asimismo, se observa un incremento en la presencia de habilidades blandas, especialmente comunicación, trabajo en equipo y pensamiento crítico. El idioma inglés aparece con una frecuencia comparable a las principales skills técnicas. En cuanto a los requisitos, la modalidad híbrida y la jornada completa predominan en las ofertas. También se identifican diferencias entre portales en términos de completitud y estructura de la información. El estudio demuestra la utilidad de combinar Web Scraping y NLP para analizar tendencias laborales en tiempo real y ofrece una visión actual a competencias clave para el perfil de Data Analyst en Barcelona.

1. Introducción

El crecimiento del sector de datos ha impulsado una demanda creciente de perfiles especializados en análisis y gestión de información. En este contexto, los portales de empleo constituyen una fuente clave para identificar tendencias del mercado laboral y comprender qué habilidades y requisitos solicitan las empresas. Sin embargo, la información publicada suele ser heterogénea y no estructurada, lo que dificulta su análisis sistemático.

Este estudio analiza las ofertas de empleo para el perfil de *Data Analyst* en Barcelona mediante un pipeline basado en Web Scraping y Procesamiento del Lenguaje Natural (NLP), con el fin de identificar patrones en habilidades técnicas, competencias transversales y requisitos laborales. El problema de investigación se centra en determinar qué competencias son más relevantes y cómo varía la información entre distintos portales. Los objetivos específicos incluyen: recopilar ofertas reales mediante scraping, procesar y estandarizar los textos con NLP, extraer y cuantificar skills y requisitos, y comparar tendencias entre plataformas. Este análisis ofrece una visión actualizada de las competencias clave que definen el perfil profesional de Data Analyst en el mercado local.

2. Metodología

La metodología del estudio se organizó en cinco etapas principales: **extracción de datos, pre-procesamiento, procesamiento mediante NLP, estructuración y visualización**. Cada etapa se implementó en notebooks independientes, lo que permitió mantener un flujo modular, reproducible y fácilmente auditable.

2.0. Diseño de la investigación y fuentes de datos

El estudio se centró en ofertas de empleo para el perfil de *Data Analyst* publicadas en tres portales ampliamente utilizados en España: **LinkedIn, Indeed y Adzuna**. Estas plataformas fueron seleccionadas por su volumen de publicaciones, diversidad de empresas y relevancia en la búsqueda de empleo en el sector tecnológico. Los registros analizados corresponden a ofertas publicadas en Barcelona durante el periodo de extracción.

2.1. Extracción de Datos

La recopilación de información se realizó mediante Web Scraping y consumo de API, utilizando Selenium y peticiones HTTP según el portal. Esta fase se implementó en los siguientes notebooks:

- WS Indeed.ipynb: Automatiza la navegación en Indeed mediante Selenium, gestionando paginación, pop-ups y selectores dinámicos. Extrae título, empresa, ubicación, resumen y enlace de ofertas.
- WS LinkedIn.ipynb: Implementa scraping autenticado mediante cookies persistentes. Se adapta al sistema de carga progresiva de LinkedIn y extrae descripciones completas de las ofertas.
- API Adzuna.ipynb: Utiliza la API oficial de Adzuna para obtener ofertas estructuradas, incluyendo metadatos como salario, ubicación y categoría profesional.
- Reconstruccion Adzuna.ipynb: completar los datos obtenidos por API mediante scraping adicional para recuperar descripciones completas cuando no están disponibles en la respuesta original.

Los datos obtenidos se almacenaron en formato tabular y se consolidaron en un dataset unificado para su posterior tratamiento.

2.2. Pre-Procesamiento de Datos

Esta fase se centró en la limpieza y estandarización inicial de los registros, garantizando la coherencia entre portales:

- Preparacion_datos.ipynb: Unifica columnas, normaliza formatos, completa campos faltantes cuando es posible y adapta la estructura de los datasets provenientes de los distintos portales.
- Depuracion_datos.ipynb: Elimina duplicados, gestiona valores ausentes y asegura la consistencia entre portales. Se aplican reglas de validación para garantizar la calidad del dataset final.

2.3. Procesamiento de Datos (NLP)

Se aplicó un pipeline de Procesamiento del Lenguaje Natural para transformar las descripciones textuales en información analítica. Esta fase se implementó en:

- NLP extraccion_skills.ipynb: Limpieza del texto, tokenización y extracción de skills mediante un diccionario ampliado manualmente y técnicas de detección de skills emergentes basadas en embeddings MiniLM.
- NLP extraccion_requisitos.ipynb: Identificación y estandarización de requisitos laborales: modalidad, tipo de contrato, jornada, nivel educativo y experiencia requerida. Se aplican reglas lingüísticas y patrones semánticos para clasificar cada requisito.

El resultado es un conjunto de atributos estructurados que permiten comparar ofertas entre portales.

2.4. Estructuración de Datos

- Estructuracion_skills_requisitos.ipynb: Integra los resultados del NLP en tablas finales listas para análisis. Se generan estructuras normalizadas para:
 - skills por oferta
 - familias profesionales
 - requisitos estructurados
 - tablas globales por portal
 - porcentajes y métricas comparativas

Esta fase prepara los datos para su análisis y visual.

2.5. Visualización de Datos

- Visualizacion.ipynb: Generan gráficos descriptivos y comparativos utilizando Matplotlib y Seaborn:
 - barplots globales y por portal
 - heatmaps de requisitos y skills
 - boxplots de complejidad de roles
 - treemaps y wordclouds
 - análisis de completitud (N/A)
 - comparaciones porcentuales entre portales

Estas visualizaciones permiten identificar tendencias, patrones y diferencias entre plataformas de empleo.

3. Resultados

El proceso de extracción y depuración generó un conjunto final de **261 ofertas** provenientes de LinkedIn, Indeed y Adzuna, con información estructurada sobre título, empresa, ubicación, descripción y metadatos asociados.

3.1. Completitud de los datos

LinkedIn presentó el mayor nivel de detalle en campos como modalidad, jornada y experiencia, mientras que Adzuna mostró el mayor porcentaje de valores ausentes. Indeed se situó en un punto intermedio. Las tablas de porcentajes permitieron cuantificar la presencia de valores “N/A” en cada requisito.

3.2. Distribución de familias profesionales

Las familias predominantes fueron Hard y Soft Skills, Data, Business Intelligence (BI) e Idiomas, con variaciones entre portales. Los gráficos de barras apiladas reflejaron estas diferencias (Fig.1).

3.3. Skills extraídas

La extracción de habilidades identificó como más frecuentes SQL, Python, Power BI, estadística, Excel e inglés (Fig.2). Las soft skills como comunicación,





Figura 2. Top-10 skills globales



trabajo en equipo, pensamiento crítico, también mostraron una presencia significativa. Los barplots globales y por portal permitieron visualizar estas tendencias (Fig.3).

3.4. Requisitos laborales

En general todos los requisitos mostraron alto porcentaje de ausencia, en especial Adzuna. La modalidad híbrida y remota, nivel senior y educativo grado fueron las más comunes (Fig.4). Los heatmaps y barplots facilitaron la comparación entre portales.

3.5. Complejidad de las ofertas

El número de skills por oferta mostró mayor dispersión en Adzuna y mayor consistencia en LinkedIn. También se observó variabilidad en la cantidad de familias profesionales asociadas a cada oferta (Fig.5).

3.6. Visualizaciones globales

Las visualizaciones globales sintetizaron los patrones observados:

- barplots de skills,
- heatmaps de requisitos y familias,
- treemaps de skills por familia,
- wordclouds ponderadas,
- comparaciones porcentuales entre portales.

4. Discusión

Los resultados obtenidos permiten identificar patrones claros en la demanda del perfil de *Data Analyst* en Barcelona (Fig.6). La predominancia de Python, SQL y herramientas de visualización coincide con estudios recientes sobre competencias esenciales en análisis de datos, mientras que la presencia creciente de habilidades blandas (comunicación, trabajo en equipo)

Figura 3. Wordclouds de habilidades globales(skills)



Figura 4. Wordclouds de requisitos globales



refleja la necesidad de perfiles capaces de integrar capacidades técnicas con competencias interpersonales.

Las diferencias en la completitud de los datos entre portales confirman la variabilidad en la calidad de la información publicada. LinkedIn destaca por su mayor nivel de detalle, mientras que Adzuna presenta más valores ausentes, lo que justifica la aplicación de técnicas de estandarización y reconstrucción empleadas en este estudio.

La modalidad híbrida y remota aparece con mayor frecuencia en las ofertas que especifican este requisito, mientras que la modalidad presencial es prácticamente inexistente como categoría explícita. Esto sugiere que, en muchos casos, la ausencia de información sobre modalidad podría implicar presencialidad por defecto, aunque esta interpretación no puede confirmarse únicamente a partir de los datos disponibles.

Aunque el alto porcentaje de valores faltantes limita la precisión del análisis, los datos disponibles muestran una mayor presencia de perfiles senior, formación universitaria o de posgrado y modalidades híbridas o remotas. La modalidad presencial casi nunca se declara explícitamente, lo que sugiere que, en algunos casos, su ausencia podría implicar presencialidad por defecto, aunque esta interpretación no puede confirmarse únicamente con los datos analizados.

Asimismo, la variabilidad en el número de skills por oferta y en la complejidad de las familias profesionales indica diferencias en el tipo de empresas que publican en cada portal. En conjunto, los hallazgos evidencian la utilidad de combinar Web Scraping y NLP para analizar información no estructurada y ofrecen una base sólida para estudios comparativos futuros.

Figura 5. Distribución de número de familias por ofertas





Figura 6. Radar de Portales de empleo por familias



5. Conclusiones

El estudio permitió caracterizar las ofertas de empleo para *Data Analyst* en Barcelona mediante un enfoque integrado de Web Scraping y NLP, identificando una fuerte demanda de habilidades técnicas como Python, SQL y herramientas de visualización, junto con un aumento notable de habilidades blandas y del requisito del inglés.

Las diferencias entre portales en completitud y estructura refuerzan la necesidad de procesos de estandarización para obtener una visión unificada. En conjunto, los resultados ofrecen una perspectiva actualizada del mercado laboral local y demuestran la eficacia de las técnicas aplicadas para analizar tendencias en tiempo real.

Referencias

Ali, M. (2024, mayo 3). *Clasificación de textos en Python*. DataCamp. <https://www.datacamp.com/es/tutorial/text-classification-python>

Donthi, S. (2023, agosto). *Cómo tratar con datos faltantes en Python* [Curso]. DataCamp. <https://www.datacamp.com/>

Elavarasan, P. (2022, enero 18). *Natural language processing (Basics to SOTA models) – Part 1*. Digital Data Science. <https://digitaldata.science.blog/2022/01/18/natural-language-processing-basics-to-sota-models-part-1/>

Equipo editorial de IONOS. (2023, febrero 22). *Web scraping con Python: Introducción y tutorial*. IONOS Digital Guide. <https://www.ionos.es/digitalguide/paginas-web/desarrollo-web/web-scraping-con-python/>

FRIKIdelTO. (s.f.). *Curso Python desde cero orientado a web scraping (aprende a programar un bot)* [Lista de reproducción]. YouTube.

<https://www.youtube.com/playlist?list=PLheIVUbpfWZ17lCcHnoaa1RD59juFR06C>

Jarmul, K. (2026, febrero). *Introducción al procesamiento del lenguaje natural en Python* [Curso]. DataCamp. <https://www.datacamp.com/>

Jones, K. (2025, julio). *Trabajar con datos categóricos en Python* [Curso]. DataCamp. <https://www.datacamp.com/>

Juantorena, G. (2023, agosto 15). *Web scraping con Python – Curso con BeautifulSoup* [Video]. freeCodeCamp Español. <https://www.youtube.com/watch?v=yKi9-BfbfzQ>

Laetsch, T. (2026, marzo). *Web scraping en Python* [Curso]. DataCamp. <https://www.datacamp.com/>

Mobasher, A. (2025, julio). *Procesamiento del lenguaje natural con spaCy* [Curso]. DataCamp. <https://www.datacamp.com/>

Nehme, A. (2025, diciembre). *Limpieza de datos en Python* [Curso]. DataCamp. <https://www.datacamp.com/>

Pinilla, J. (2024, abril 24). *Tutorial de web scraping con Python y Selenium* [Video]. YouTube. <https://www.youtube.com/watch?v=Rx3j6PXmT>

Ramakers, C. (2026, enero). *Introducción a las API en Python* [Curso]. DataCamp. <https://www.datacamp.com/>

Siddiqui, L. (2024, septiembre 3). *How to learn NLP from scratch in 2026: An expert guide*. DataCamp. <https://www.datacamp.com/blog/how-to-learn-nlp>

Takyar, A. (s.f.). *Natural language processing: A comprehensive overview*. LeewayHertz. <https://www.leewayhertz.com/natural-language-processing/>

Tech Portal Formación. (2025, marzo 5). *Web scraping con Python. BeautifulSoup y Selenium fácil* [Video]. YouTube. <https://www.youtube.com/live/tGrHD5X20EA>

Trad, F. (2025, julio). *Procesamiento del lenguaje natural (PLN) en Python* [Curso]. DataCamp. <https://www.datacamp.com/>

Zanini, A. (s.f.). *How to scrape with Python: A step-by-step guide*. Bright Data. <https://brightdata.es/blog/procedimientos/web-scraping-with-python>

Castellanos Pérez, R. (2026). *Data_Analytics* [Repositorio]. GitHub. https://github.com/castellanorn/Data_Analytics/tree/main/Sprint%2013